第一部分：单项选择题（推测）

(1) [凸集] 凸集的是：（考察凸集定义：任意两点连线都在集合内）

若一个集合 C 为**凸集**，则对于集合内任意两点 $x_1, x_2 \in C$，以及任意满足 $0 \leq \lambda \leq 1$ 的实数 λ，以下线性组合点（即两点之间的连线）依然在集合内：

$$x = \lambda x_1 + (1-\lambda)x_2 \in C$$

(2) A*算法是：（考察搜索算法：启发式搜索/最佳优先搜索）

A***算法（A-star algorithm）** 是一种在图形平面上，有多个节点的路径中，寻找起点到终点之间**最短路径**的经典**启发式搜索算法。**

它被广泛应用于游戏开发、地图导航和机器人路径规划中，核心在于它比普通的深度优先或广度优先搜索更"聪明"。

A* 算法的精髓在于它对每个待搜索节点 n 的评估值 $f(n)$：

- $g(n)$：**实际代价。**表示从起点到当前节点 n 已经走过的路径成本。
- $h(n)$：**启发式预估代价。**表示从当前节点 n 到终点的**预计**成本（这是算法的"智慧"所在）。
- $f(n)$：**综合评估代价。**模型优先探索 $f(n)$ 最小的节点。

$h(n)$ 的选择决定了搜索效率：

- **欧几里得距离**：计算两点间的直线距离（适用于可以在任何方向移动的场景）。
- **曼哈顿距离**：计算两点在坐标轴上的距离绝对值之和（适用于只能水平或垂直移动的网格地图）。
- **关键原则**：如果 $h(n)$ 的预估值始终小于或等于实际从 n 到终点的最短距离，那么 A* 算法**一定能找到最短路径**，这种特性被称为"可采纳性"（Admissibility）。

(3) 有监督学习与半监督学习的区别是：（考察标记数据量的不同）

特性	有监督学习 (Supervised Learning)	半监督学习 (Semi-supervised Learning)
数据组成	**全部**数据都有明确标签	少量带标签数据 + **大量**无标签数据
核心目标	学习输入到输出的映射函数	利用无标签数据提升模型泛化能力
获取成本	标签获取非常昂贵且耗时	利用廉价的无标签数据，节省标注成本
典型算法	SVM, 随机森林, 深度神经网络	自训练 (Self-training), 生成对抗网络 (GAN)

(4) 在二元分类问题中，[如果]真实标签也为负，[且预测也为负，称为真反例]：（考察混淆矩阵定义）

	预测为阳性 (Positive)	预测为阴性 (Negative)
真实为阳性	**TP (真正例)**	**FN (假负例)**
真实为阴性	**FP (假正例)**	**TN (真负例)**

(5) 哪种度量指标可以[衡量分类模型的综合性能，如F1-score]： (考察评价指标)

F1-Score (F1分数)　AUC-ROC　P-R曲线平衡点

(6) 设计决策树模型时，[防止过拟合的常用方法是剪枝]： (考察模型优化)　**重点**
(7) [在神经网络训练中，常用] mini-batch [梯度下降法]： (考察优化策略)
(8) 在卷积神经网络中，[池化层/pooling] 滤器，输出的数据为： (考察下采样机制)
(9) [RNN/GRU/LSTM] LSTM 神经网络模型[解决长距离依赖问题的机制是门控机制]： (考察序列建模)
(10) Transformer 神经网络架构[的核心是注意力机制 (Attention Mechanism)]： (考察主流架构)

第二部分：填空题（推测）

(1) [ReLU/Sigmoid/Tanh] 激活函数（名称或公式均可）
(2) 神经网络模型[中常用的正则化方法是 Dropout]，在线性回归模型中[常用的方法是 L1/L2 正则化]
(3) [图像任务中] 请写出两种可用的数据增强[方法：旋转、平移、缩放、翻转等]
(4) [提升模型泛化能力的增] 强方法：[交叉验证]；超参数：[学习率、批量大小、迭代次数] 与 [模型架构参数]。

第三部分：简答题（推测）

(1) 用 [拉格朗日乘子法/KKT条件] 求解： $\min_x f(x), \text{s.t. } x \in F$ (考察约束优化基础)

(2) [请根据 TP, TN, M 计算准确率 (Accuracy) 或 错误率]： (考察混淆矩阵计算：$Acc = \frac{TP+TN}{M}$)

(3) [什么是] k折交叉验证： (考察模型评估的鲁棒性)

将原始数据集随机划分为 k **个互不相交、大小相等的子集（折）**，然后进行 k 次训练与评估：

1. **轮次 1**：选取第 1 个子集作为**验证集**，其余 $k-1$ 个子集作为**训练集。**
2. **轮次 2**：选取第 2 个子集作为**验证集**，其余 $k-1$ 个子集作为**训练集。**
3. ...
4. **轮次 k**：选取第 k 个子集作为**验证集**，其余 $k-1$ 个子集作为**训练集。**
5. **最终评估**：将这 k 次验证的性能指标（如准确率、F1 分数）取**平均值**，作为模型最终的性能评估结果。

克服样本偏差：简单的"训练集-测试集"划分可能因为随机性导致某一部分难例恰好全在测试集中，从而使模型评分过低或过高。k 折交叉验证让每条数据都有机会参与测试。

充分利用数据：在小样本数据集上，如果划分出 20% 作为测试集，模型可能因训练数据不足而效果不佳。k 折交叉验证确保了每一轮训练都能使用绝大部分数据。

评估更稳健：通过 k 次结果的方差，可以判断模型的稳定性——如果 k 次的结果差异巨大，说明模型对数据分布非常敏感（可能是过拟合的信号）。

第四部分：应用分析题（推测）

(1) [背景：时间序列数据，如] 商品的销量。按以下方式划分数据集：[直接按时间先后顺序划分为训练集和测试集]。

- **分析：** 这种划分存在"数据泄露"或"未来信息不可知"的问题。如果模型在训练中接触到了测试集（未来的数据），会导致评估分数虚高。

- **改进：** 使用**滚动窗口验证 (Rolling Window Validation)** 或 **时间序列交叉验证 (Time Series Split)**，确保训练集的时刻始终早于测试集，避免“穿越”现象。