人工智能与深度学习

马尔可夫决策过程与 Q 学习

华中科技大学 机械科学与工程学院

陈伟

2026

背景

动态决策过程

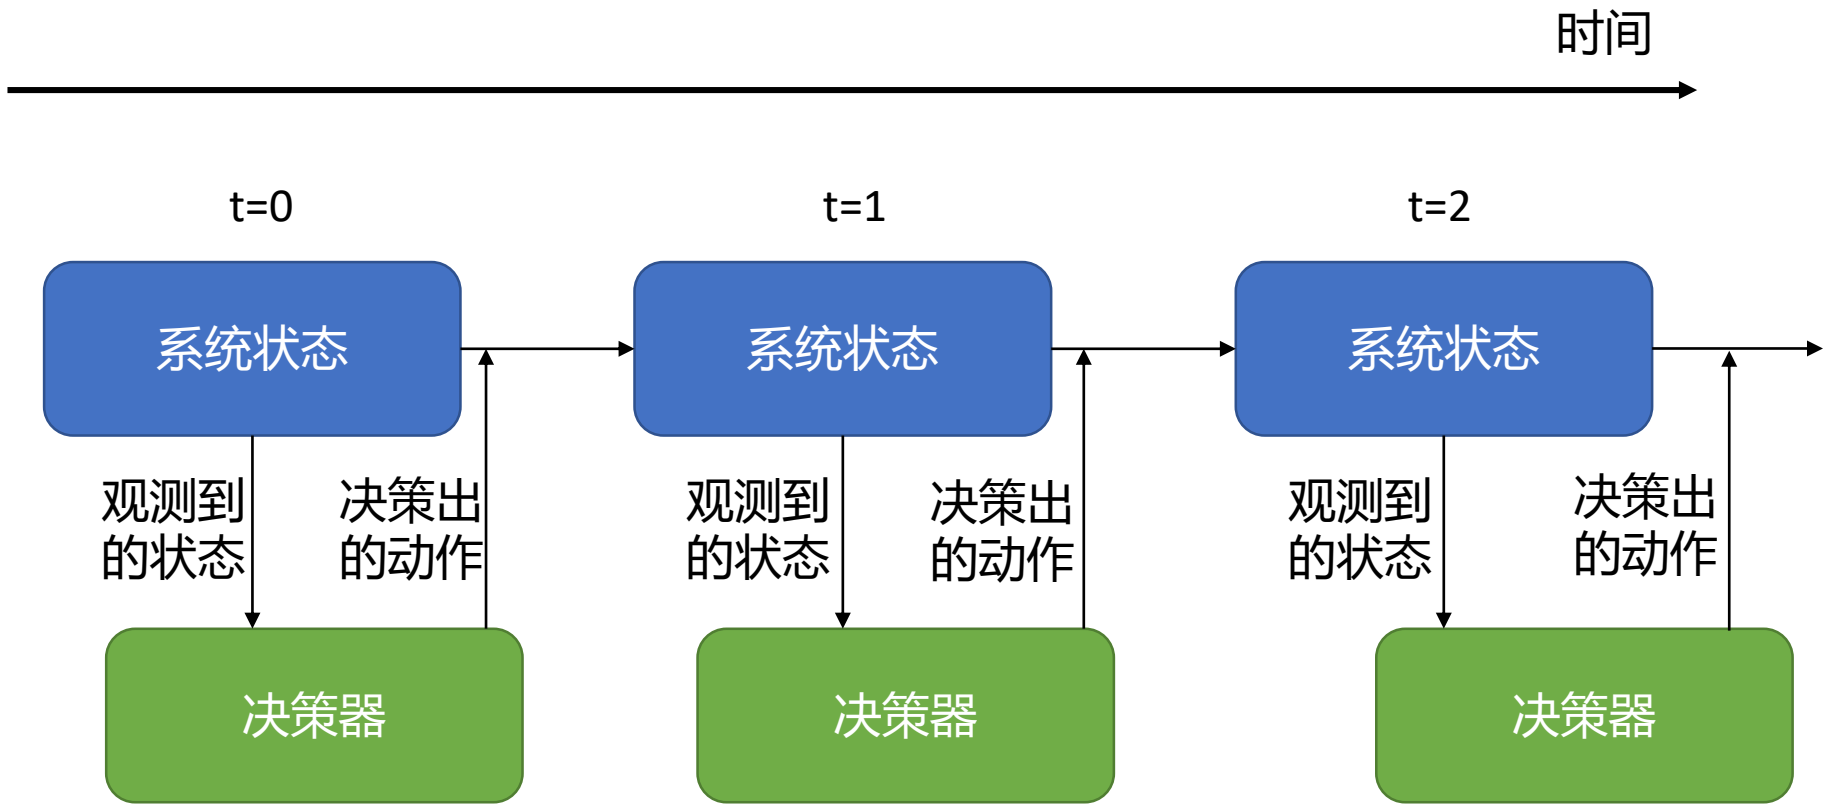
- 控制机器人完成任务
- 汽车自动驾驶
- 下围棋







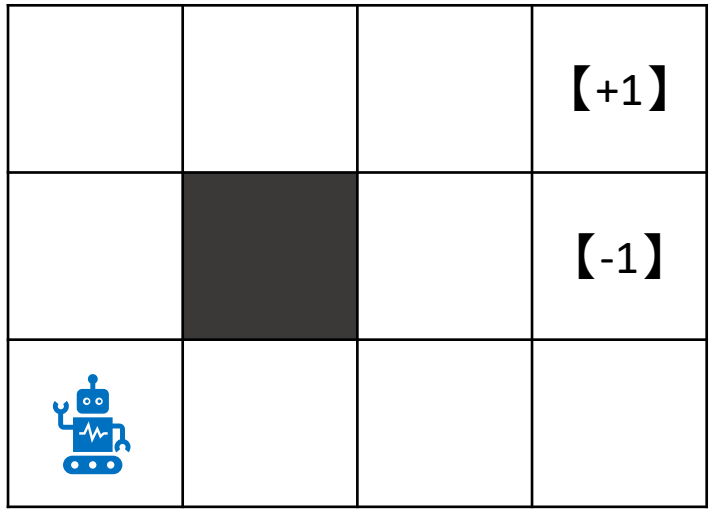
动态决策过程


时间
t=0
t=1
t=2
系统状态
系统状态
系统状态
观测到的状态
决策出的动作
观测到的状态
决策出的动作
观测到的状态
决策出的动作
决策器
决策器
决策器

网格上的路径规划问题

- **机器人由起点 [1,1] 前往终点 [4,3] 或终点 [4,2]**
  - 奖励：[4,3] 为+1
  - 奖励：[4,2] 为-1
  - 奖励：每一步 -0.04

- **最佳策略是?**



网格上的路径规划问题

- 机器人由任一点前往终点 [4,3] 或终点 [4,2] 的**最佳策略**

→	→	→	【+1】
↑		↑	【-1】
↑或→	→	↑	←

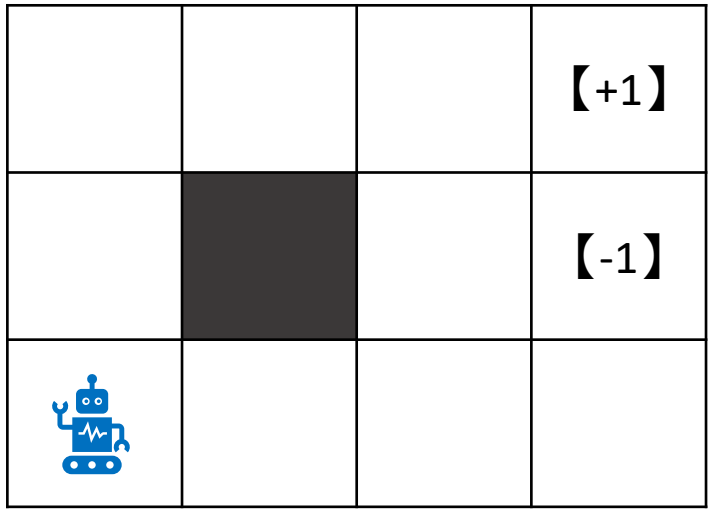
网格上的路径规划问题

- 机器人由任一点前往终点 [4,3] 或终点 [4,2] 的**最优奖励**

0.88 →	0.92 →	0.96 →	【+1】
0.84 ↑		0.92 ↑	【-1】
0.80 ↑→	0.84 →	0.88 ↑	0.84 ←

网格上的随机路径规划问题

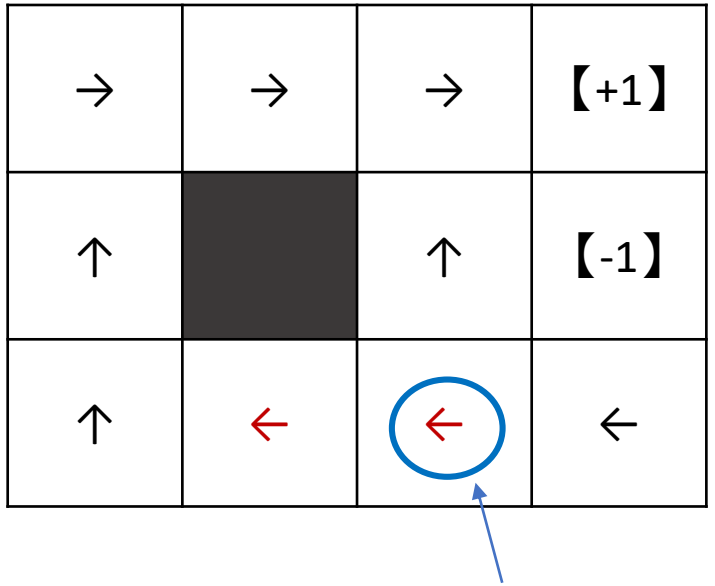
- **机器人由起点 [1,1] 前往终点 [4,3] 或终点 [4,2]**
  - 奖励：[4,3] 为+1
  - 奖励：[4,2] 为-1
  - 奖励：每一步 -0.04



- **假如动作是随机的……**
  - 动作个
    - 80% 的概率，机器人按照指令运动
    - 20% 的概率，（由于信号干扰等原因）机器人随机运动

网格上的路径规划问题

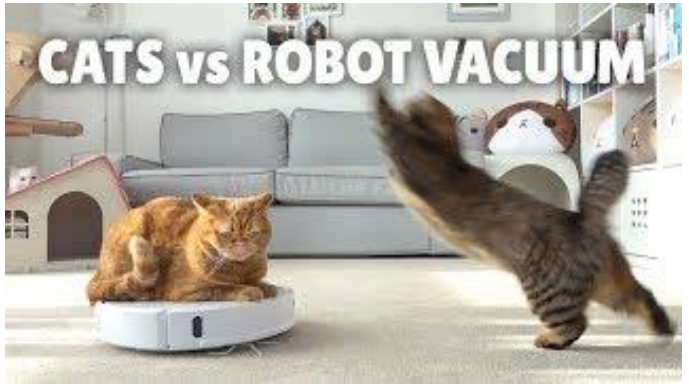
- 机器人由任一点前往终点 [4,3] 或终点 [4,2] 的**最佳策略**可能会有所变化



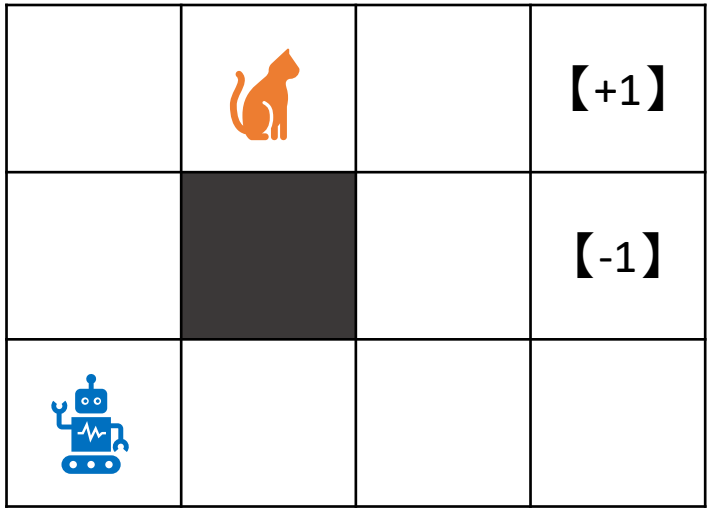
向上走虽近，但有风险，未必值得

网格上的随机路径规划问题

- **假设机器人希望尽量避开猫**
  - 撞上猫奖励减0.5



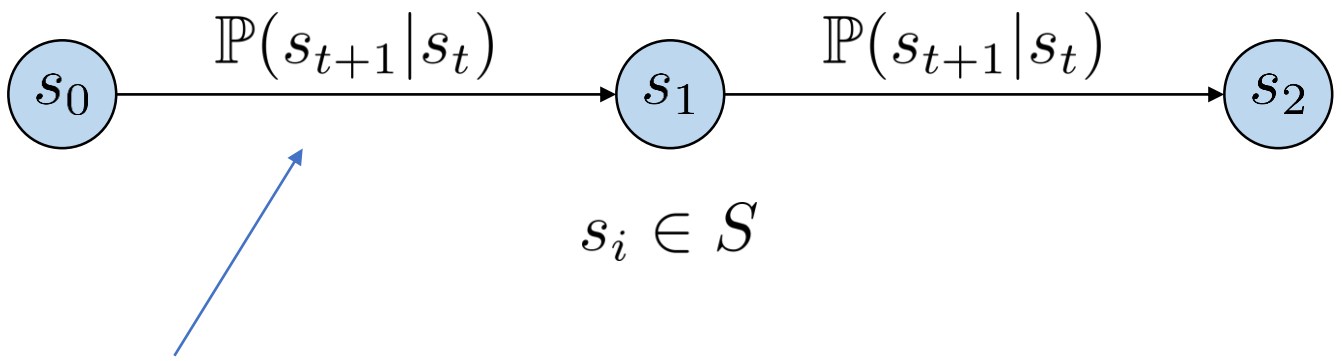
- **而猫在网格上随机走动**
  - 猫的当前位置可观察
  - 猫的下一步动作随机
  - 一次最多移动一格



马尔可夫决策过程
(Markov Decision Process，MDP)

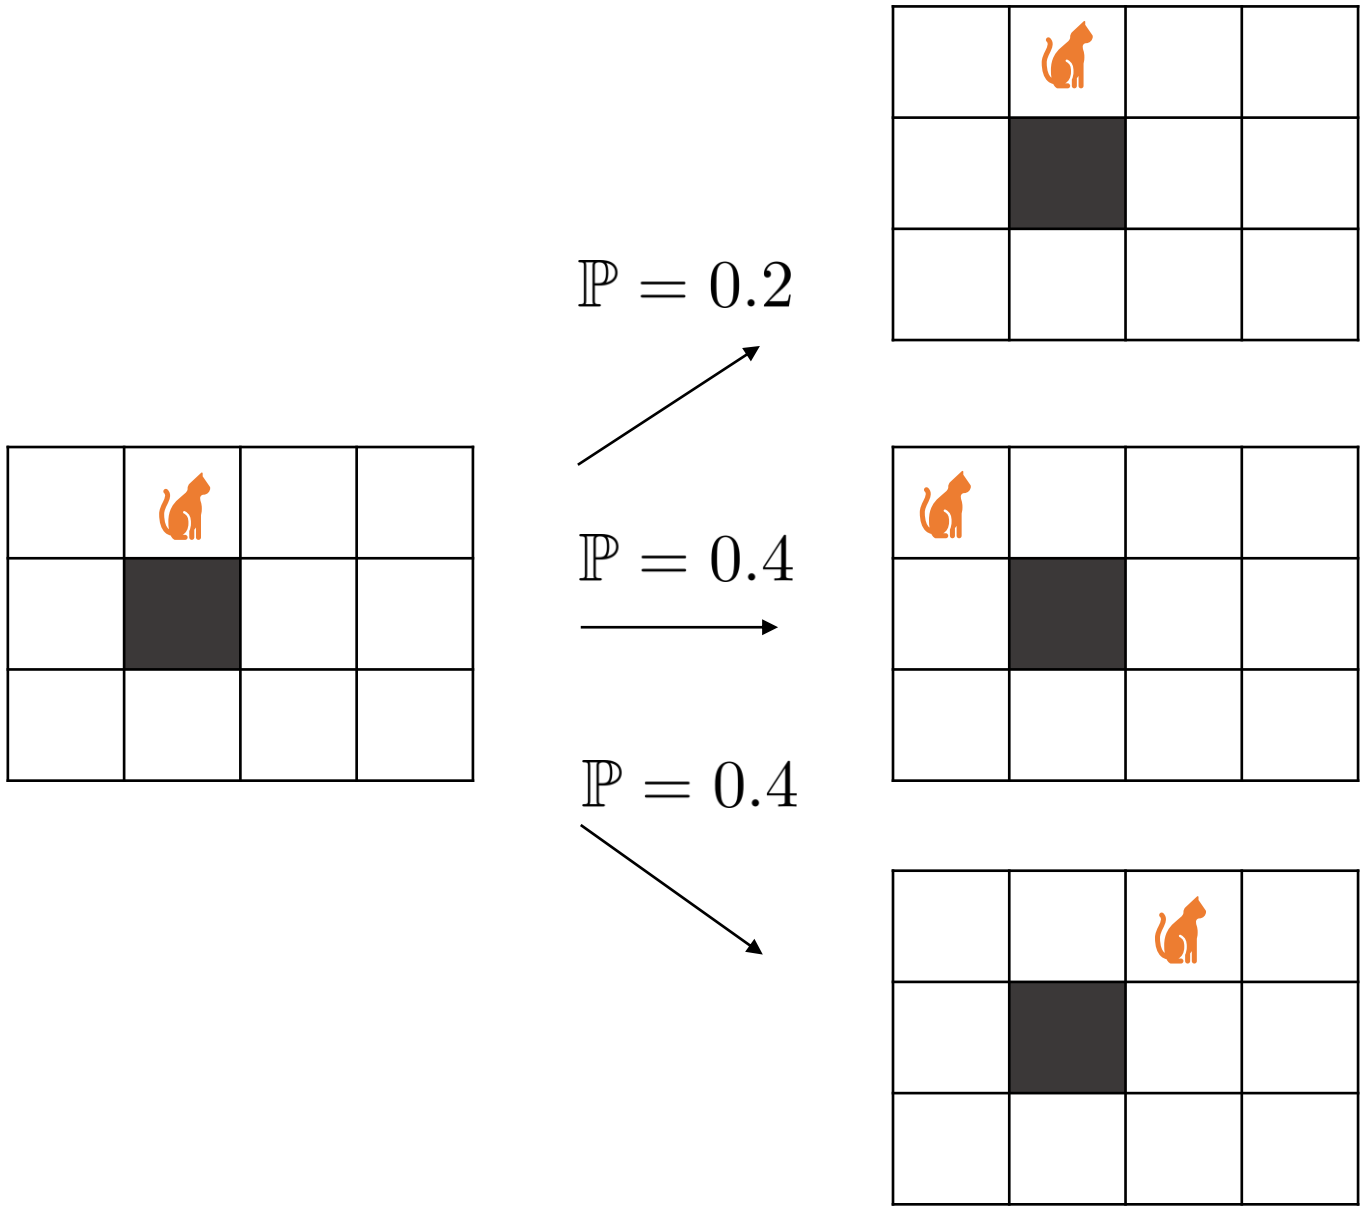
马尔可夫过程

- 马尔可夫过程包括以下部分
  - 所有可能的状态（state）的集合 S
  - 状态转移概率 $\mathbb{P}(s'|s)$

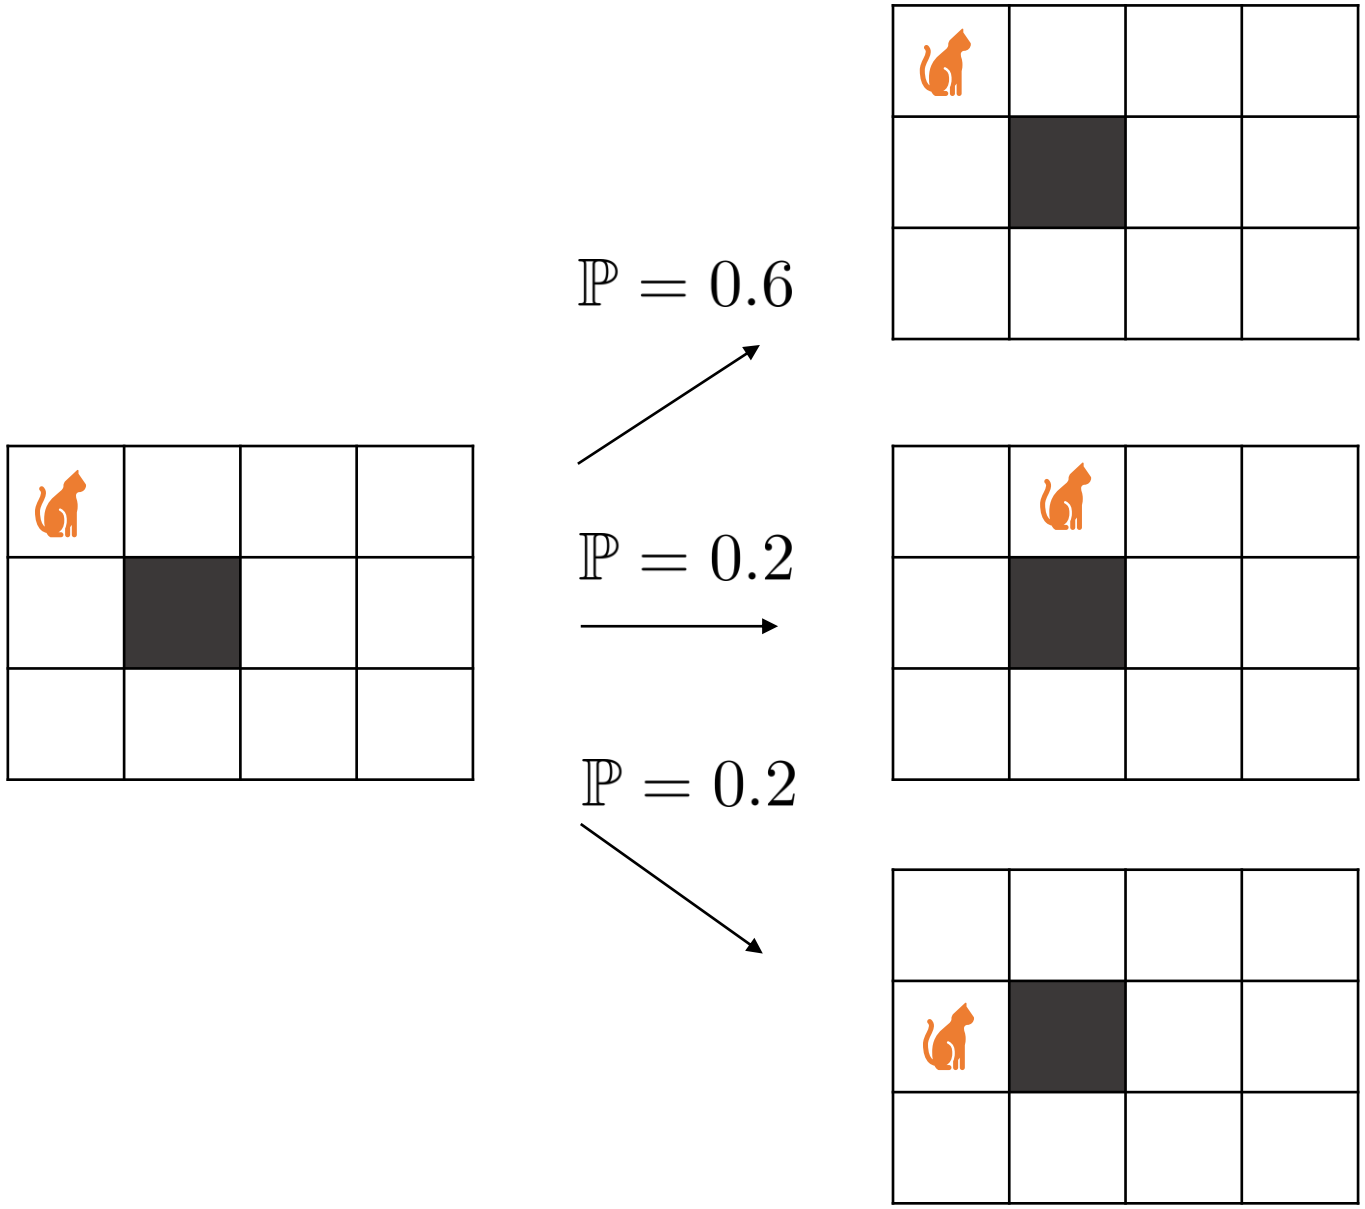


马尔可夫性质：此概率由s_t决定，不受$s_{t-1}, s_{t-2}, \ldots$影响

马尔可夫过程示例



马尔可夫过程示例

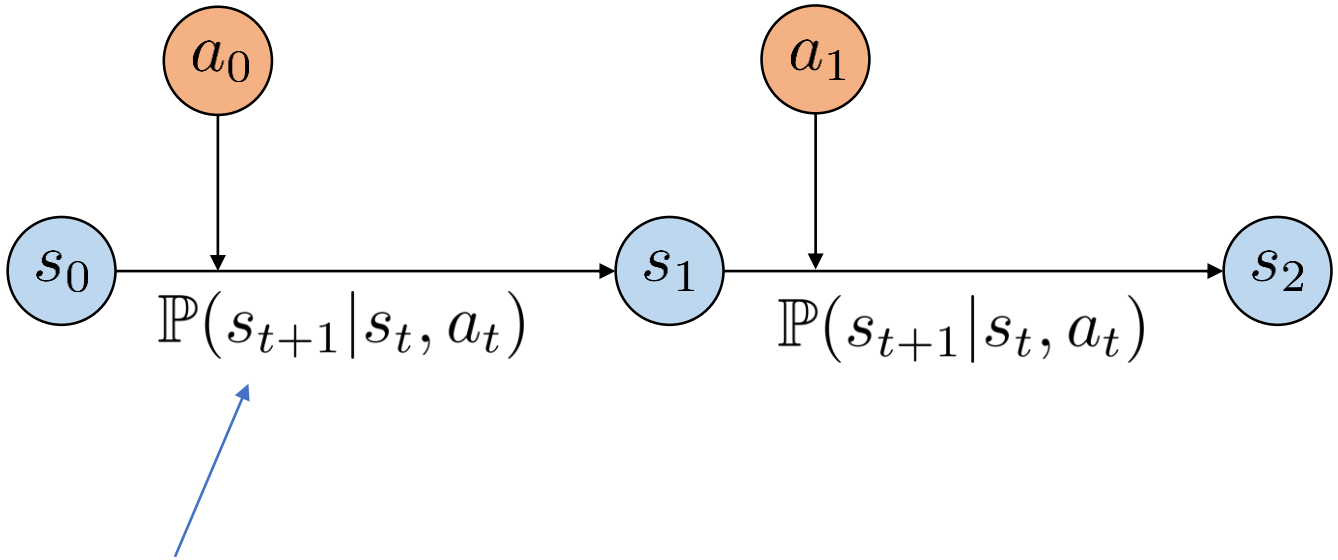


马尔可夫决策过程

- 马尔可夫决策过程包括以下部分
  - 所有可能的状态（state）的集合 S
  - 所有可能的动作（action）的集合 A
  - 状态转移概率 $\mathbb{P}(s'|s,a)$
  - 奖励函数 $R(s,a,s')$
  - （可选）一个或多个终止状态 s_T

马尔可夫决策过程

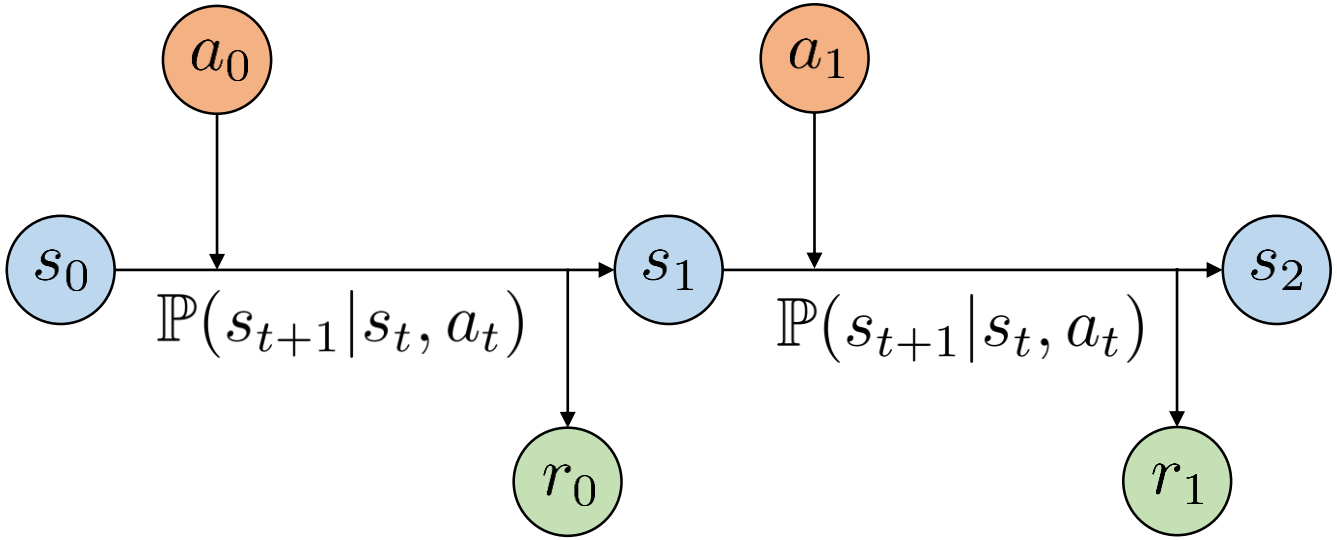
- $s_i \in S, a_i \in A$



马尔可夫性质：此概率由 s_t 和 a_t 决定，不受 $s_{t-1}, a_{t-1}, s_{t-2}, a_{t-2}\ldots$ 影响

马尔可夫决策过程

- $s_i \in S, a_i \in A$

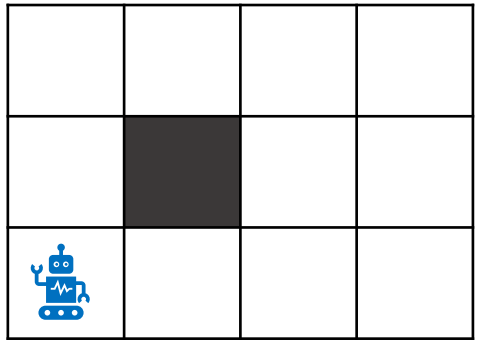


$$r_t = R(s_t, a_t)$$

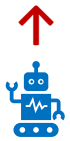
有时我们假设 $r = R(s, a)$；实际上的奖励可能是一个关于 s、a 和 s' 的随机变量，我们这里仅考虑该随机变量的期望，即 $R(s, a) = \mathbb{E}[R(s, a, s')]$。

马尔可夫决策过程示例

状态：



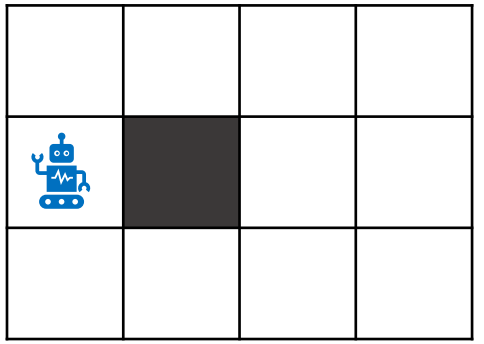
动作：



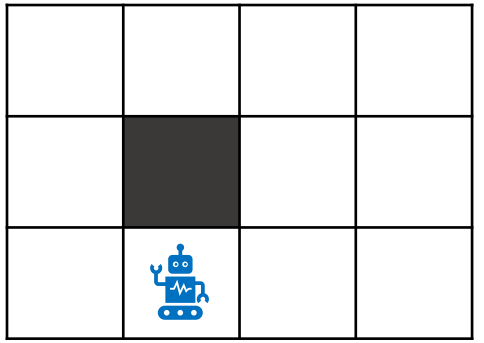
$\mathbb{P} = 0.8$

$\mathbb{P} = 0.1$

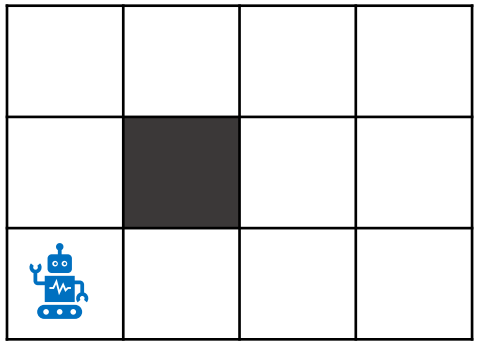
$\mathbb{P} = 0.1$



$R = -0.04$



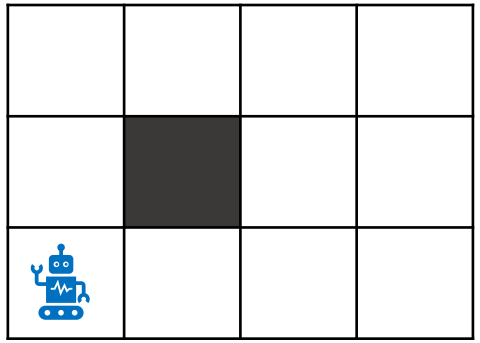
$R = -0.04$



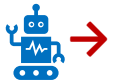
$R = -0.04$

马尔可夫决策过程示例

状态：



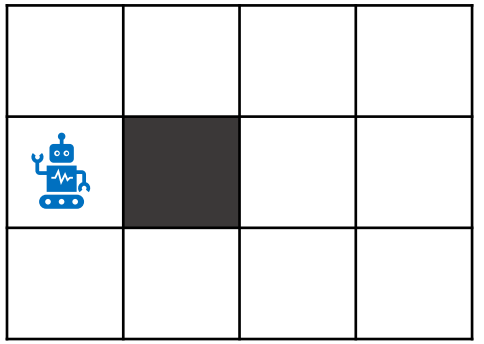
动作：



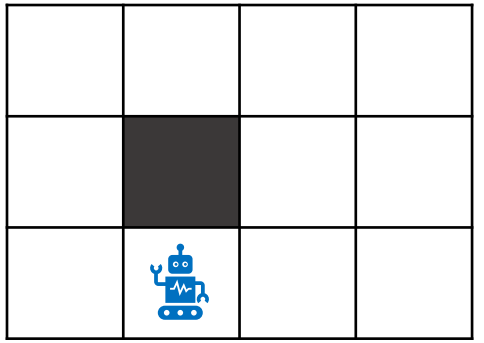
$\mathbb{P} = 0.1$

$\mathbb{P} = 0.8$

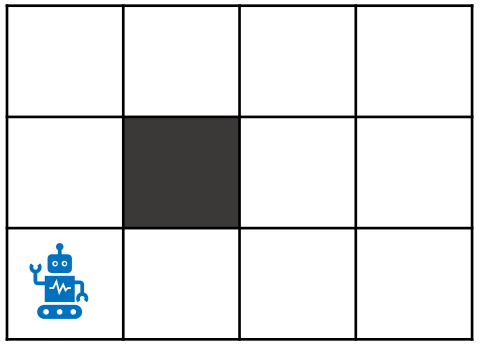
$\mathbb{P} = 0.1$



$R = -0.04$

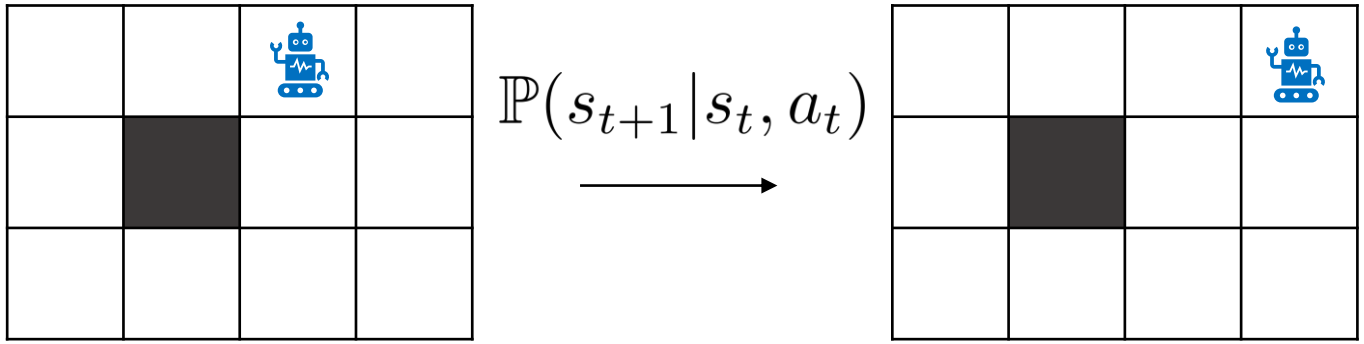


$R = -0.04$

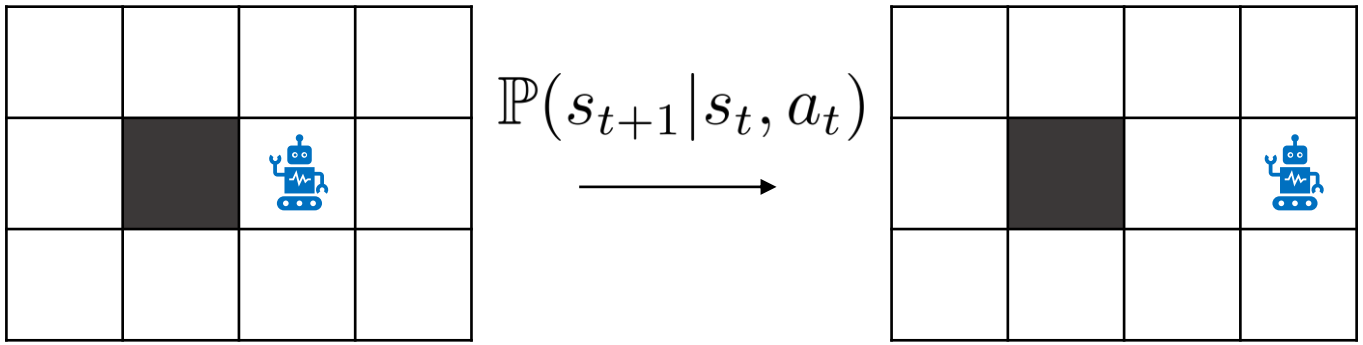


$R = -0.04$

马尔可夫决策过程示例



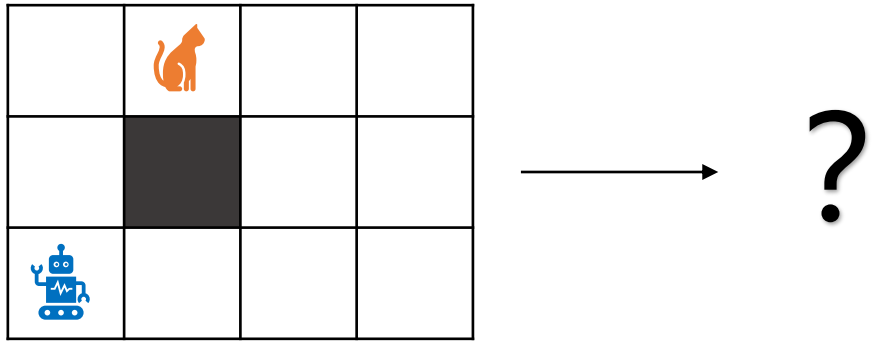
奖励函数 $R(s, a, s') = +1$



奖励函数 $R(s, a, s') = -1$

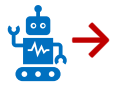
马尔可夫决策过程示例

状态：

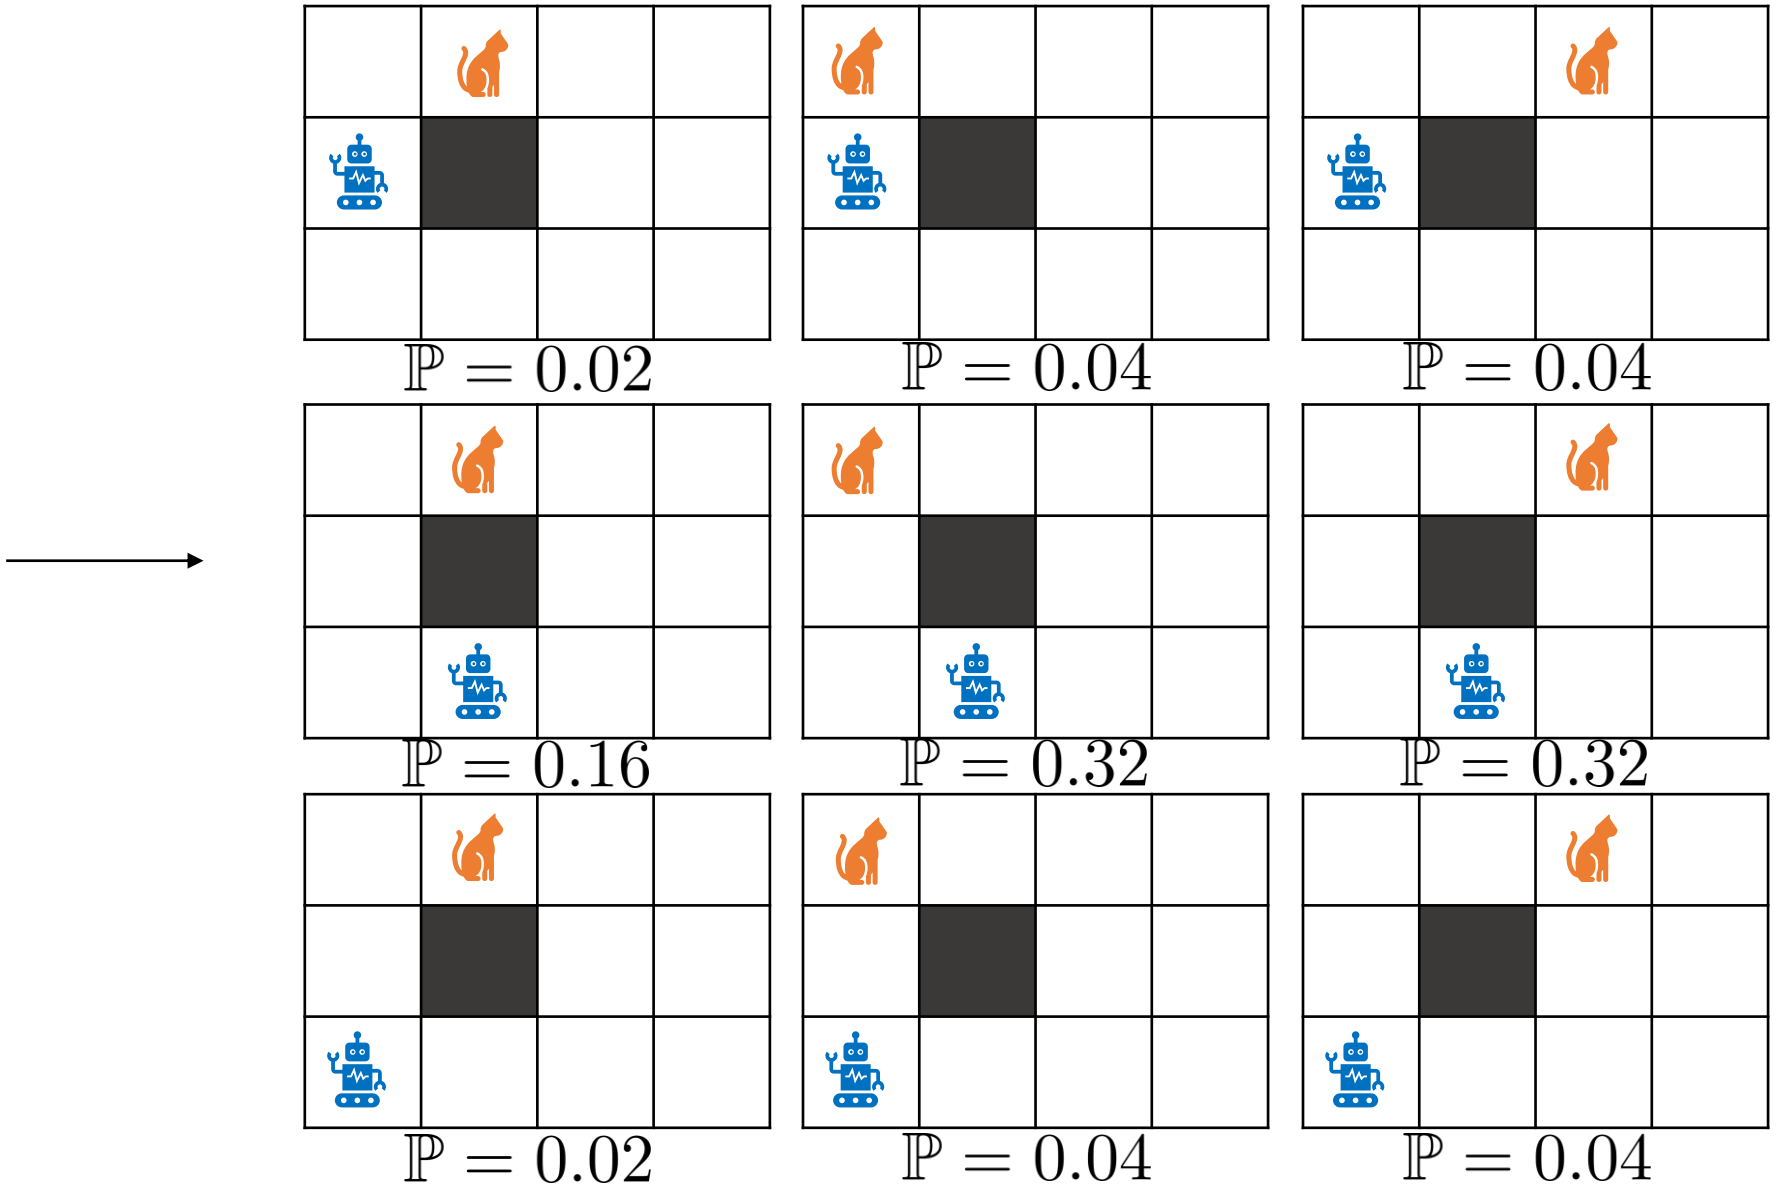


?

动作：



马尔可夫决策过程示例

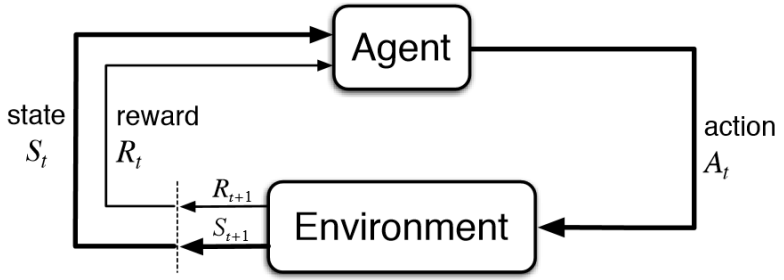

$\mathbb{P} = 0.02$
$\mathbb{P} = 0.04$
$\mathbb{P} = 0.04$
$\mathbb{P} = 0.16$
$\mathbb{P} = 0.32$
$\mathbb{P} = 0.32$
$\mathbb{P} = 0.02$
$\mathbb{P} = 0.04$
$\mathbb{P} = 0.04$

马尔可夫决策过程

- **我们看到了两类随机性**
  - 被控制系统自身的随机性（机器人动作执行的不确定）
  - 环境中的不随机性（猫行动的不确定性）

- **在马尔可夫决策过程的描述中，这两类随机性无本质区别**
  -

都能在状态转移概率 $\mathbb{P}(s'|s,a)$ 中体现



什么是 Agent？什么是 Environment？

不必纠结，只要定义好 MDP 中的状态就行

使用动态规划
（dynamic programming）
求解马尔可夫决策过程

马尔可夫决策过程的最优解

- 考虑有终止状态 s_T 的马尔可夫决策过程。

  我们希望设计策略（policy）$\pi : S \to A$，以控制系统的状态。

  由于马尔科夫决策过程有随机性，即使使用确定的策略 $a_t = \pi(s_t)$，系统的轨迹和奖励 $s_0, a_0, r_0, s_1, a_1, r_1, s_2 \ldots$ 也是随机的

马尔可夫决策过程的最优解

- 每个策略 $\pi(\cdot)$，都有对应的奖励期望

$$\mathbb{E}\sum_{t\geq 0} r_t$$

我们想找使奖励期望最大的最优策略 π^*。

注意：对于带有随机性的马尔可夫决策过程问题，我们关注的最优解是指最优策略；这样的问题可能并不存在一条（有意义的）最优轨迹

马尔可夫决策过程的最优解

- 假如系统没有终止状态 s_T，以下期望可能不存在最小值（任何策略下，奖励期望都是 $+\infty$)

$$\mathbb{E}\sum_{t\geq 0} r_t$$

这时我们可以考虑给奖励加上折扣因子（discouting factor），降低遥远的未来的收益的重要性。加入折扣因子后，这个期望就存在最小值了

$$\mathbb{E}\sum_{t\geq 0} \gamma^t r_t, \quad 0 < \gamma \leq 1$$

任意策略的价值函数

- 假设我们有了一个策略 $\pi(\cdot)$（可以是任意策略，未必是最优的 $\pi^*(\cdot)$）

  策略 $\pi(\cdot)$ 的价值函数（value function）是指从状态 s 开始，在后续都使用策略 $\pi(\cdot)$ 的情况下，总收益（即总奖励）的期望

$$V^{\pi}(s) = \mathbb{E}\Big[\sum_{t\geq 0} r_t \Big| s_0 = s, \pi(\cdot)\Big]$$

网格上的路径规划问题

- 机器人由任一点前往终点 [4,3] 或终点 [4,2]
- 一种策略（如图箭头所示）及其相应的价值

0.88 →	0.92 →	0.96 →	【+1】
0.84 ↑		0.92 ↑	【-1】
0.80 →	0.84 →	0.88 ↑	-1.04 ↑

最优策略的价值函数

- 显然，最优策略 $\pi^*(\cdot)$ 也有其对应的价值函数

$$V^*(s) = \mathbb{E}\left[\sum_{t\geq 0} r_t \middle| s_0 = s, \pi^*(\cdot)\right]$$

其含义可以理解为，从状态 s 到终止状态的最优价值（即最大奖励）

最优策略的价值函数 vs 任意给定策略的价值函数

- $\pi^*(\cdot)$ 为最优策略，其对应的价值函数为

$$V^*(s) = \mathbb{E}\left[\sum_{t\geq 0} r_t \middle| s_0 = s, \pi^*(\cdot)\right]$$



- 对于任意给定策略 $\pi(\cdot)$，其对应的价值函数为

$$V^{\pi}(s) = \mathbb{E}\left[\sum_{t\geq 0} r_t \middle| s_0 = s, \pi(\cdot)\right]$$

最优策略的价值函数

- 假如我们知道了最优策略对应的价值函数 $V^*(s)$，我们可以由该价值函数反推最优策略吗？

$$V^*(s) \xrightarrow{?} \pi^*(\cdot)$$

最优策略的价值函数：示例（确定性问题）

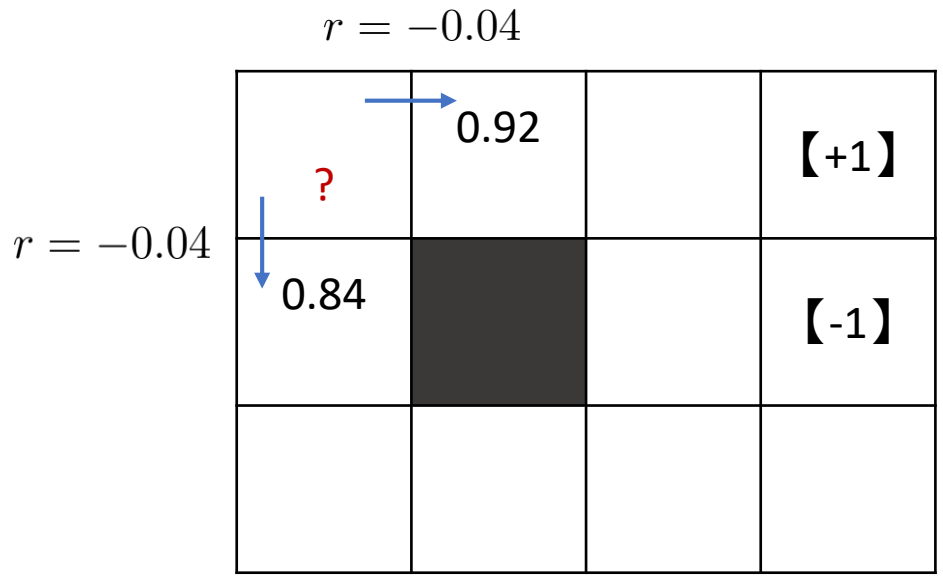
- 假设我们想要求 $\pi^*([1,3])$
- 我们需要已知以下这些信息：$\pi^*([1,3]) \in \{\text{down}, \text{right}\}$
- $[1,3] + \text{down} \rightarrow [1,2]$ $\quad V^*([1,2]) = 0.84$

  $[1,3] + \text{right} \rightarrow [2,3]$ $\quad V^*([2,3]) = 0.92$
- $R([1,3], \text{down}) = -0.04$

  $R([1,3], \text{right}) = -0.04$

最优策略的价值函数：示例（确定性问题）

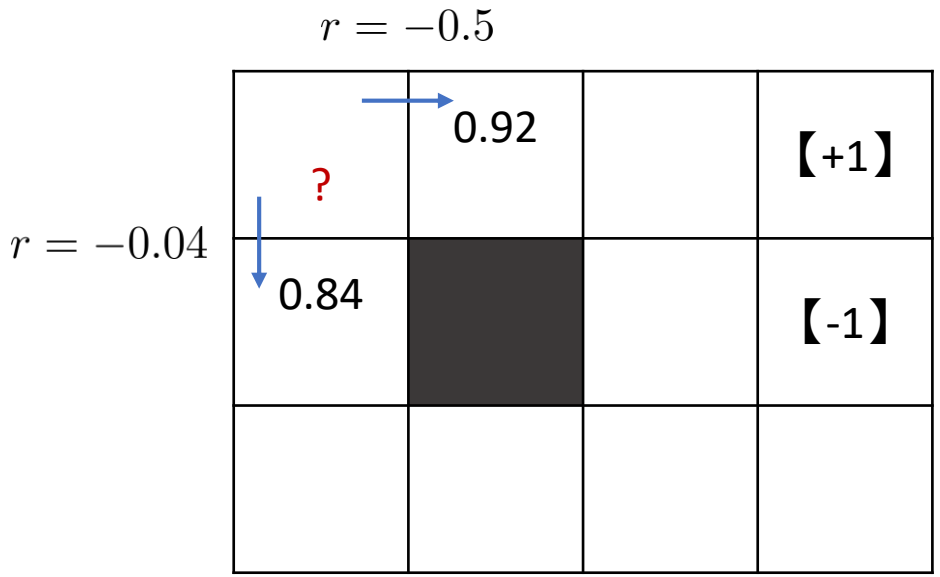
- 假如选择往右，从当前状态 $[1,3]$ 开始以后所有收益的期望是 $r + V^*(s') = -0.04 + 0.92 = 0.88$
- 假如选择往下，从当前状态 $[1,3]$ 开始以后所有收益的期望是 $r + V^*(s') = -0.04 + 0.84 = 0.8$
- **经比较，最优策略应该向右，最优收益为0.88**



最优策略的价值函数：示例（确定性问题）

- 提问：若单步的奖励函数和两个状态的最优价值函数如下图所示，[1,3] 的最优策略是?

- 最优策略应该向下，最优收益为0.8



最优策略的价值函数：确定性和随机性问题

- 假如我们已知所有 $s \in S$ 的最优策略价值函数 $V^*(s)$，我们可以用以下方法计算最优策略 $\pi^*(s)$

$$\pi^*(s) = \arg\max_a [R(s,a) + \mathbb{E}V^*(s')],$$

其中 $s' \sim \mathbb{P}(\cdot|s,a)$

- 注意：随机情况下，$\mathbb{E}V^*(s')$ 通常不是 $V^*(\mathbb{E}s')$：我们需要 (1)求 s' 的分布，(2)继而得到 $V^*(s')$ 的分布，(3)再求 $V^*(s')$ 的期望

最优策略的价值函数

- $$\pi^*(s) = \arg\max_a [R(s,a) + \mathbb{E}V^*(s')],$$

- 由上式，不难发现

$$V^*(s) = \max_a [R(s,a) + \mathbb{E}V^*(s')],$$

其中 $s' \sim \mathbb{P}(\cdot|s,a)$

Bellman Equation

计算最优策略的价值函数

- **若马尔可夫决策过程及其各参数都是已知的，只要知道了最优策略的价值函数，就可以推导出最优策略**

- **如何求最优策略的价值函数呢?**
  - 方法一：价值迭代
  - 方法二：策略迭代

价值迭代

- 在价值迭代时，我们构造一系列的“近似价值函数” $V^i(\cdot)$，

$$V^{i+1}(s) = \max_a [R(s,a) + \mathbb{E}V^i(s')],$$

其中 $s' \sim \mathbb{P}(\cdot|s,a)$

- 当问题满足一定条件时，多次迭代后计算出的 $V^{i+1}(\cdot)$ 会逼近最优策略的价值函数 $V^*(\cdot)$

价值迭代

- 从某个初始价值函数 $V^0(\cdot)$ 开始，

$$V^1(s) = \max_a [R(s,a) + \mathbb{E}V^0(s')],$$

这个过程与“将 $V^0(s')$ 看作最优策略的价值函数，反求最优策略”类似

- 回顾：反求最优策略：

$$\pi^*(s) = \arg\max_a [R(s,a) + \mathbb{E}V^*(s')],$$

价值迭代

- 从某个初始价值函数 $V^0(\cdot)$ 开始，对所有 $s \in S$ 计算

$$V^1(s) = \max_a [R(s,a) + \mathbb{E}V^0(s')],$$

再对所有 $s \in S$ 计算

$$V^2(s) = \max_a [R(s,a) + \mathbb{E}V^1(s')],$$

.....

最终，

$$V^i(\cdot) \approx V^*(\cdot)$$

策略迭代

- 在策略迭代时，我们构造一系列的策略 $\pi^i(\cdot)$，

$$\pi^{i+1}(s) = \arg\max_a [R(s,a) + \mathbb{E}V^{\pi^i}(s')],$$

其中 $s' \sim \mathbb{P}(\cdot|s,a)$，$V^{\pi^i}(\cdot)$ 是 $\pi^i(\cdot)$ 的价值函数，即

$$V^{\pi^i}(s) = \mathbb{E}\Big[\sum_{t\geq 0} r_t \Big| s_0 = s, \pi^i(\cdot)\Big]$$

- 当问题满足一定条件时，多次迭代后计算出的 $\pi^{i+1}(\cdot)$ 会等于最优策略 $\pi^*(\cdot)$，$V^{\pi^{i+1}}$ 会等于最优策略的价值函数 $V^*(\cdot)$

策略迭代

- 策略迭代包含交替进行的两个步骤：策略评估(policy evaluation)和策略改进(policy improvement)

  策略评估：给定一个策略 $\pi(\cdot)$，计算其价值函数 $V^{\pi}(\cdot)$

  策略改进：给定一个策略的价值函数 $V^{\pi}(\cdot)$，设计一个更好的策略 $\pi^{+}(\cdot)$

策略迭代

- 在策略迭代时，我们构造一系列的策略 $\pi^i(\cdot)$，

$$\pi^{i+1}(s) = \arg\max_a [R(s,a) + \mathbb{E}V^{\pi^i}(s')],$$

策略改进

其中 $s' \sim \mathbb{P}(\cdot|s,a)$，$V^{\pi^i}(\cdot)$ 是 $\pi^i(\cdot)$ 的价值函数，即

策略评估

$$V^{\pi^i}(s) = \mathbb{E}\left[\sum_{t\geq 0} r_t \middle| s_0 = s, \pi^i(\cdot)\right]$$

- 计算顺序：$\pi_0(\cdot) \to V^{\pi_0}(\cdot) \to \pi_1(\cdot) \to V^{\pi_1}(\cdot) \to \ldots$

策略迭代与价值迭代的变体

- **策略评估有多种不同的方法**
  - 可以基于迭代，基于轨迹采样，等等
- **策略改进与评估的时机**
  - 不必每次对每个状态 s 都进行价值评估，即只要完成了部分评估，我们就可以进入下一步策略改进
  - 不必每次对每个状态 s 都进行策略更新，即只要完成了部分策略改进，我们就可以进入下一步策略评估

Q 函数

最优策略的价值函数：模型未知的情况

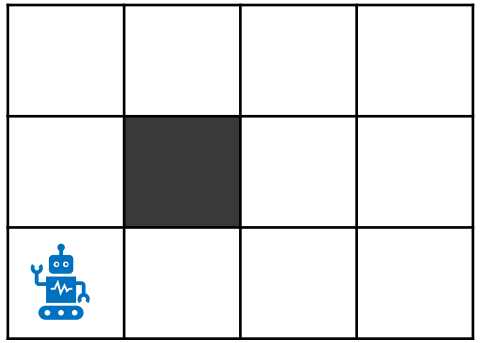
- 若**马尔可夫决策过程及其各参数都是已知的**，只要知道了最优策略的价值函数，就可以推导出最优策略

- 假如我们不知道该马尔可夫决策过程的状态转移概率……

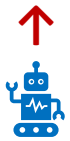
假如我们不知道 $\mathbb{P}(\cdot|s,a)$ 的话……

最优策略的价值函数：模型未知的情况

状态：



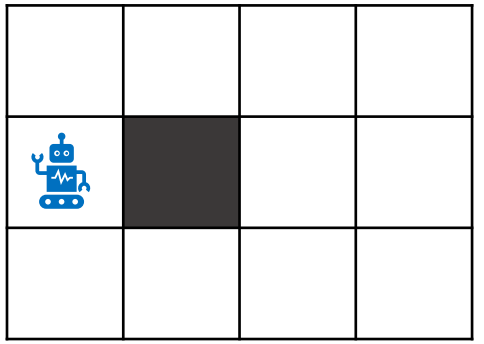
动作：



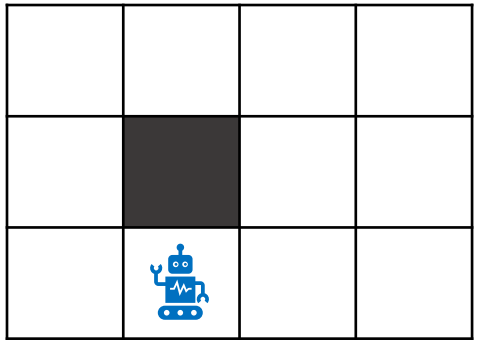
$\mathbb{P} = ?$

$\mathbb{P} = ?$

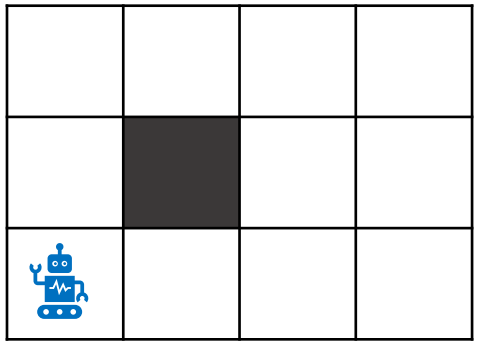
$\mathbb{P} = ?$



$R = -0.04$



$R = -0.04$



$R = -0.04$

最优策略的价值函数：模型未知的情况

- 假如我们已知所有 $s \in S$ 的最优策略价值函数 $V^*(s)$，我们可以用以下方法计算最优策略 $\pi^*(s)$

$$\pi^*(s) = \arg\max_a [R(s,a) + \mathbb{E}V^*(s')],$$

其中 $s' \sim \mathbb{P}(\cdot|s,a)$

未知，无法计算

- 注意：随机情况下，$\mathbb{E}V^*(s')$ 通常不是 $V^*(\mathbb{E}s')$：我们需要 (1)求 s' 的分布，(2)继而得到 $V^*(s')$ 的分布，(3)再求 $V^*(s')$ 的期望

Q 函数

- 价值函数是指从状态 s 开始，在后续都使用策略 $\pi(\cdot)$ 的情况下，总收益（即总奖励）的期望

$$V^{\pi}(s) = \mathbb{E}\Big[\sum_{t\geq 0} r_t \Big| s_0 = s, \pi(\cdot)\Big]$$

Q 函数(Q-value function)是指在状态 s 使用动作 a 之后，在后续都使用策略 $\pi(\cdot)$ 的情况下，总收益（即总奖励）的期望

$$Q^{\pi}(s,a) = \mathbb{E}\Big[\sum_{t\geq 0} r_t \Big| s_0 = s, a_0 = a, \pi(\cdot)\Big]$$

最优策略的 Q 函数

- 与价值函数的情况类似，最优策略 $\pi^*(\cdot)$ 也有其对应的 Q 函数

$$Q^*(s,a) = \mathbb{E}\Big[\sum_{t\geq 0} r_t \Big| s_0 = s, a_0 = a, \pi^*(\cdot)\Big]$$

- 最优策略的价值函数 $V^*(s)$ 和 Q 函数 $Q^*(s,a)$ 的对应关系为

$$V^*(s) = \max_a Q^*(s,a)$$

最优策略的 Q 函数

- 假如我们已知所有 $s \in S,\ a \in A$ 的最优策略 Q 函数 $Q^*(s,a)$，我们可以用以下方法计算最优策略 $\pi^*(s)$

$$\pi^*(s) = \arg\max_a [Q^*(s,a)],$$

- 最优策略的 Q 函数也有其对应的 Bellman Equation

$$Q^*(s,a) = R(s,a) + \mathbb{E}[\max_{a'} Q^*(s',a')],$$

其中 $s' \sim \mathbb{P}(\cdot|s,a)$

最优策略的 Q 函数：模型未知的情况

- 假如我们已知所有 $s \in S,\ a \in A$ 的最优策略 Q 函数 $Q^*(s,a)$，我们可以用以下方法计算最优策略 $\pi^*(s)$

$$\pi^*(s) = \arg\max_a [Q^*(s,a)],$$

只要知道了最优策略的 Q 函数，
无需模型也可以求出最优策略

最优策略的 Q 函数

- 如何求最优策略的 Q 函数?

- 最优策略的 Q 函数也可以通过价值迭代求得

Q 函数的价值迭代

- 在价值迭代时，我们构造一系列的“近似 Q 函数” $Q^i(\cdot,\cdot)$，

$$Q^{i+1}(s,a) = R(s,a) + \mathbb{E}[\max_{a'} Q^i(s',a')],$$

其中 $s' \sim \mathbb{P}(\cdot|s,a)$

- 当问题满足一定条件时，多次迭代后计算出的 $Q^{i+1}(\cdot,\cdot)$ 会逼近最优策略的 Q 函数 $Q^*(\cdot,\cdot)$

注意：进行 Q 函数的价值迭代时，需要已知模型

Q学习：
从动态规划到强化学习

使用模型 vs 使用数据

- 有没有可能在**模型未知**的情况下，通过**学习**的方式，计算最优策略?
- 若**已计算**出（近似的）最优策略 Q 函数，我们可以在不用模型的情况下，得到最优策略
- 可目前为止，我们课程里讲到的计算近似最优 Q 函数的方法，都需要用到模型

回顾 Q 函数的价值迭代

- 我们可以构造一系列的“近似 Q 函数” $Q^i(\cdot,\cdot)$，

$$Q^{i+1}(s,a) = R(s,a) + \mathbb{E}[\max_{a'} Q^i(s',a')],$$

其中 $s' \sim \mathbb{P}(\cdot|s,a)$

我们需要 (1)估计 s' 的分布，(2)继而估计 $\max_{a'} Q^i(s',a')$ 的分布，(3)再求 $\max_{a'} Q^i(s',a')$ 的期望

未知模型，则无法计算

使用数据估计期望

- **随机变量的期望，可以通过采样来估计**
  - 采集多个样本，取平均值 → 对样本期望的估计
- **蒙特卡洛（Monte Carlo）方法：使用随机抽样解决计算问题**
  - 一个样本可以是指一条轨迹

蒙特卡洛方法的基本思想

- 假设我们想估计一个随机变量 v 的期望。

  蒙特卡洛方法的基本思想，是通过仿真等方法采样得到一系列该随机变量的样本 $v_1, v_2, ..., v_N$，然后通过样本的均值来估计的期望

$$M = \frac{1}{N} \sum_{k=1}^{N} v_k$$

蒙特卡洛方法的基本思想

- $$M_N = \frac{1}{N}\sum_{k=1}^{N} v_k$$

这种估计方法可以随着新样本 v_{N+1} 的到来而随时更新

$$M_{N+1} = M_N + \frac{1}{N+1}(v_{N+1} - M_N)$$

强化学习

- 强化学习：通过仿真或实验得到的系统轨迹，$s_0, a_0, r_0, s_1, a_1, r_1, \ldots$ 来得到“样本”，用以计算该马尔可夫决策过程的最优策略

Q 学习 - 最基础的强化学习算法

- Q 函数的价值迭代

$$Q^{i+1}(s,a) = R(s,a) + \mathbb{E}[\max_{a'} Q^i(s',a')],$$

其中 $s' \sim \mathbb{P}(\cdot|s,a)$。我们对其做一点改变，再设计基于数据采样的迭代算法，

$$Q^{i+1}(s,a) = (1-\eta)Q^{i+1}(s,a) + \eta R(s,a) + \eta \mathbb{E}[\max_{a'} Q^i(s',a')],$$



$$Q(s,a) \leftarrow (1-\eta)Q(s,a) + \eta[R(s,a,s') + \max_{a'} Q(s',a')],$$

更新

Q学习

- $$Q(s,a) \leftarrow (1-\eta)Q(s,a) + \eta[R(s,a,s') + \max_{a'} Q(s',a')],$$

这里需要进行一步仿真（需用到一个 (s,a,r,s') 样本）

- 上式也可以写成如下等价形式

$$Q(s,a) \leftarrow Q(s,a) + \eta[R(s,a,s') + \max_{a'} Q(s',a') - Q(s,a)],$$

学习率　　根据差异，更新Q函数

Q学习（带折扣因子）

- 如果我们定义的最优收益考虑了折扣因子，

$$\mathbb{E}\sum_{t\geq 0}\gamma^t r_t, \quad 0<\gamma\leq 1,$$

Q 学习中也要相应地增加折扣因子 γ

$$Q(s,a)\leftarrow Q(s,a)+\eta[R(s,a,s')+\gamma\max_{a'}Q(s',a')-Q(s,a)]$$

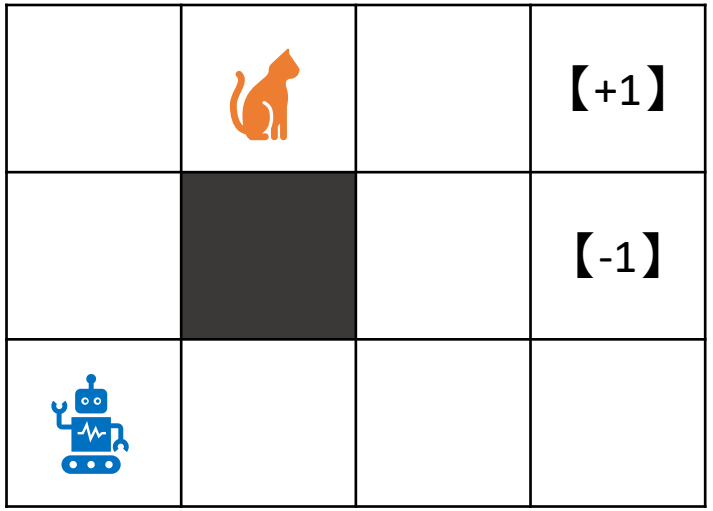
Q 学习示例

- 无需知道猫的运动规律（但要求猫是马尔可夫过程）
- 无需知道机器人执行失灵的概率（但要求机器人是马尔可夫决策过程）

- 只要能获得一些轨迹

$$s_0, a_0, r_0, s_1, a_1, r_1, \ldots$$

我们就可以估计最优 Q 函数



Q 学习示例

- 共有 11*11 = 121 种状态
- 其中，终止状态有 11*2 = 22 种

- 共有 4 种动作，有些动作在有些状态下不可行

共有 253 种 (s, a) 组合

2	2	3	1
2		3	1
2	2	3	2

每个机器人所在位置对应的动作数
（假设终止状态对应“终止动作”）

Q 学习示例

- $$Q(s,a) \leftarrow Q(s,a)+\eta[R(s,a,s')+\gamma \max_{a'} Q(s',a')-Q(s,a)]$$

- **由于只有两百多种 (s,a) 的组合，我们可以用一个“表格”来储存记录所有的 Q(s,a) 的值**

- **根据轨迹，利用 Q 学习公式，来不断更新表格中 Q(s,a) 的值**

- 最终 $Q(s,a)$ 有可能收敛到 $Q^*(s,a)$

Q 学习过程中的策略

- **Q 学习收敛后，我们可以根据收敛后近似最优的 Q 函数得到最优策略**

- **Q 学习过程中，我们应该使用什么策略来生成轨迹样本呢?**
  - 我们希望所有可能的 (s,a,s') 组合在轨迹中都有体现
  - 很多时候，我们也希望多更新最优策略下出现可能性更高的(s,a)组合；或者希望在采集轨迹样本的过程中，奖励也尽量高

$$Q(s,a) \leftarrow Q(s,a)+\eta[R(s,a,s')+\gamma \max_{a'} Q(s',a')-Q(s,a)]$$

Q 学习过程中的策略



- 探索（exploration） vs 利用（exploitation）